

Previsione dell'insolvenza creditizia

Progetto del corso di Introduzione al Pensiero Computazionale e alla Data Science
a.a. 2025/26

Gruppo N. 1
Cota Miriam (1216760)

Monopoli Alessandro (1232093)

Ponissi Giuliana (1216083)

Luglio 2026

Sommario

Questo lavoro analizza il dataset *Default of Credit Card Clients* (30.000 clienti di carte di credito taiwanesi) con l'obiettivo di prevedere l'insolvenza sul pagamento del mese successivo. Dopo una fase di comprensione e pulizia dei dati e un'analisi esplorativa, confrontiamo tre modelli di classificazione: regressione logistica, k -Nearest Neighbors e Random Forest. Alla soglia di decisione standard la Random Forest ottiene i risultati migliori (accuracy 0,813; F1 sulla classe insolvente 0,464), ma tutti i modelli mostrano recall modesti sulla classe minoritaria, conseguenza dello sbilanciamento delle classi. Una serie di esperimenti di robustezza mostra che i risultati sono stabili rispetto alla proporzione dello split e al numero di alberi, mentre la calibrazione della soglia di decisione incide sui risultati più della scelta dell'algoritmo: abbassando la soglia a 0,3, la regressione logistica raggiunge F1 0,503. Lo storico dei ritardi di pagamento, e in particolare lo stato del pagamento più recente, risulta di gran lunga il predittore più importante. Tutto il materiale del progetto è disponibile nel repository GitHub:

<https://github.com/etooooooooo/Gruppo-1--Data-Science>.

1 Introduzione

La previsione dell'insolvenza creditizia è un problema centrale per gli istituti finanziari: identificare in anticipo i clienti a rischio consente di limitare le perdite e di gestire meglio il credito concesso. Si tratta di un classico problema di *classificazione binaria*: a partire dalle caratteristiche di un cliente, il modello deve prevedere se nel mese successivo il cliente sarà insolvente (classe 1) oppure no (classe 0).

L'obiettivo del progetto non è solo addestrare un modello, ma sviluppare un'analisi completa e riproducibile: comprensione del dataset e dei suoi limiti, analisi esplorativa guidata da domande e ipotesi, confronto fra modelli di natura diversa, verifica della robustezza dei risultati rispetto alle principali scelte di modellazione e interpretazione critica dei risultati. Il lavoro è stato svolto con Python e le librerie presentate durante il corso (`pandas`, `seaborn`, `matplotlib`, `scikit-learn`), versionato su GitHub e documentato in un notebook eseguibile.

Nel corso del progetto è stato utilizzato un assistente LLM (Claude) per la convalida del codice, il miglioramento della resa grafica e la risoluzione di errori, come documentato nel notebook; tutto il codice è stato rivisto e compreso dai membri del gruppo.

2 Dataset

Il dataset *Default of Credit Card Clients* [1] contiene 30.000 record relativi a clienti di carte di credito taiwanesi, osservati da aprile a settembre 2005. Ogni record comprende 23 variabili esplicative: il credito concesso (`LIMIT_BAL`), quattro variabili demografiche (sesso, istruzione, stato civile, età), sei variabili di stato dei pagamenti mensili (`PAY_0`–`PAY_6`, dove -1 indica

pagamento puntuale e i valori ≥ 1 i mesi di ritardo), sei importi di estratto conto (BILL_AMT1–BILL_AMT6) e sei importi pagati (PAY_AMT1–PAY_AMT6). La variabile target è binaria: 1 se il cliente è risultato insolvente il mese successivo, 0 altrimenti.

2.1 Qualità dei dati e criticità

Il dataset non presenta valori mancanti né identificativi duplicati. L’analisi ha però evidenziato tre criticità rilevanti, che abbiamo documentato e gestito.

Sbilanciamento delle classi. Solo il 22,1% dei clienti è insolvente. Un classificatore banale che predice sempre la classe maggioritaria otterrebbe quindi un’accuracy del 77,9%: questo valore costituisce la *baseline* di riferimento e impone di valutare i modelli anche con precision, recall e F1-score sulla classe minoritaria.

Valori non documentati. Le variabili EDUCATION (valori 0, 5, 6, in 468 casi) e MARRIAGE (valore 0, in 54 casi) contengono codici assenti dalla documentazione. Li abbiamo accorpati nella categoria “altro”. Anche le variabili PAY_* contengono i valori non documentati -2 e 0, che coprono la maggioranza delle osservazioni: confrontandoli con gli importi fatturati, l’interpretazione più coerente è che -2 indichi assenza di consumi nel mese e 0 l’uso del credito *revolving* (pagamento minimo). Abbiamo mantenuto tali valori trattando PAY_* come scala ordinale di gravità del ritardo.

Ridondanza e outlier. Le sei variabili BILL_AMT sono fortemente correlate fra loro (r fra 0,80 e 0,95), con conseguente multicollinearità; gli importi presentano inoltre code molto lunghe (es. PAY_AMT1: mediana 2.100 NT\$, massimo 873.552 NT\$) e valori negativi negli estratti conto, interpretabili come saldi a credito del cliente.

3 Metodologia

3.1 Analisi esplorativa

L’analisi esplorativa è stata guidata da domande e ipotesi esplicite, verificate sui dati con statistiche descrittive e grafici (boxplot, barplot, heatmap, istogrammi, grafico di regressione logistica). I risultati principali sono tre. Primo, il limite di credito distingue le due classi: la mediana è 150.000 NT\$ per i clienti solventi contro 90.000 NT\$ per gli insolventi, e la probabilità stimata di insolvenza decresce in modo monotono al crescere di LIMIT_BAL, da circa il 30% al 5% (Figura 2) — relazione da non leggere in chiave causale, dato che il limite è assegnato dalla banca in base all’affidabilità percepita del cliente. Secondo, lo stato del pagamento più recente (PAY_0) mostra la relazione più forte con il target: il tasso di insolvenza passa da circa il 13% per i clienti senza ritardi a circa il 70% per chi ha due mesi di ritardo (Figura 1). Terzo, le variabili demografiche sono poco informative: età, sesso e istruzione presentano correlazioni con il target prossime a zero, mentre le variabili PAY_* raggiungono $r \approx 0,32$.




Figura 1: Tasso di insolvenza in funzione dello stato del pagamento di settembre (PAY_0). La linea tratteggiata indica il tasso medio del campione (22,1%).




Figura 2: Probabilità stimata di insolvenza in funzione del limite di credito (stima logistica univariata su un campione di 3.000 clienti). La probabilità decresce in modo monotono senza mai avvicinarsi a 1: LIMIT_BAL, da solo, è un predittore debole.

3.2 Preparazione dei dati

Le variabili categoriche nominali (SEX, EDUCATION, MARRIAGE) sono state convertite in variabili dummy (one-hot encoding), per non imporre un ordinamento fittizio; le PAY_*, ordinali, sono state mantenute numeriche. Il dataset è stato diviso in training (70%, 21.000 clienti) e test set (30%, 9.000 clienti) in modo *stratificato*, preservando in entrambe le parti la quota di insolventi. Tutte le feature sono state standardizzate ($z = (x - \mu)/\sigma$) stimando μ e σ sul solo training set, per evitare *data leakage*: la standardizzazione è indispensabile per il k -NN, basato sulle distanze, e innocua per gli altri modelli.

3.3 Modelli

Abbiamo confrontato un modello lineare e due non lineari, tutti implementati con `scikit-learn` [2] e con seme casuale fissato per la riproducibilità.

La **regressione logistica** stima la probabilità di insolvenza tramite la funzione sigmoide applicata a una combinazione lineare delle feature:

$$P(y = 1 \mid \mathbf{x}) = \frac{1}{1 + e^{-(\beta_0 + \beta_1 x_1 + \dots + \beta_p x_p)}}, \quad (1)$$

e classifica come insolventi i clienti con probabilità prevista superiore a 0,5. È il modello più interpretabile: il segno e la grandezza dei coefficienti β_j indicano direzione e forza dell'effetto di ciascuna feature.

Il **k-Nearest Neighbors** classifica ogni cliente in base alla classe più frequente fra i k esempi di training più vicini nello spazio standardizzato delle feature. Abbiamo confrontato $k \in \{5, 15, 25, 51\}$: valori piccoli producono modelli instabili, valori grandi appiattiscono le previsioni verso la classe maggioritaria; abbiamo scelto $k = 25$ come compromesso.

La **Random Forest** aggrega le previsioni di 100 alberi di decisione, ciascuno addestrato su un campione bootstrap dei dati e su sottoinsiemi casuali delle feature. È in grado di catturare relazioni non lineari e interazioni (come il brusco salto di rischio per $\text{PAY}_0 \geq 2$) e fornisce una misura di importanza delle feature. La scelta di 100 alberi è motivata da un esperimento dedicato (Sezione 4.1).

3.4 Metriche di valutazione

Per ogni modello riportiamo accuracy, confusion matrix e, per la classe insolvente, precision, recall e F1-score, definito come media armonica:

$$F_1 = 2 \cdot \frac{\text{precision} \cdot \text{recall}}{\text{precision} + \text{recall}}. \quad (2)$$

4 Risultati

La Tabella 1 riassume le prestazioni dei tre modelli sul test set; la Figura 3 mostra le confusion matrix.

Tabella 1: Prestazioni dei modelli sul test set (9.000 clienti). Precision, recall e F1 sono riferiti alla classe “insolvente”. Baseline (classe maggioritaria): accuracy 0,779.

Modello	Accuracy	Precision	Recall	F1
Regressione logistica	0,809	0,698	0,240	0,357
k -NN ($k = 25$)	0,809	0,647	0,297	0,407
Random Forest	0,813	0,636	0,366	0,464




Figura 3: Confusion matrix dei tre modelli sul test set.

Tutti i modelli superano la baseline, ma di poco in termini di accuracy (0,809–0,813): con classi sbilanciate il confronto significativo avviene sulla classe minoritaria. Qui emergono differenze sostanziali: la regressione logistica ha la precision più alta (0,698) ma individua meno di un insolvente su quattro (recall 0,240); il k -NN migliora leggermente il recall a scapito della precision; la Random Forest offre il compromesso migliore, con il recall (0,366) e l’F1 (0,464) più alti.

L’analisi dell’importanza delle feature della Random Forest (Figura 4) conferma quanto osservato nell’analisi esplorativa: **PAY_0** è di gran lunga la variabile più importante, seguita dalle altre variabili di ritardo e dagli importi; le variabili demografiche contano poco. Coerentemente, nella regressione logistica il coefficiente positivo più forte è quello di **PAY_0** ($\beta \approx 0,65$ sulle feature standardizzate), mentre limite di credito e importi pagati di recente hanno segno negativo (riducono il rischio previsto).




Figura 4: Le dodici feature più importanti secondo la Random Forest.

4.1 Esperimenti di robustezza

Per verificare quanto i risultati dipendano dalle principali scelte di modellazione abbiamo condotto tre esperimenti.

Soglia di decisione della regressione logistica. In un problema sbilanciato in cui i falsi negativi costano più dei falsi positivi, la soglia standard di 0,5 non è necessariamente adeguata. Abbiamo quindi valutato la regressione logistica al variare della soglia (Tabella 2): abbassandola da 0,5 a 0,3 il recall quasi raddoppia (da 0,240 a 0,456) e l’F1 sale a 0,503, superando la Random Forest a soglia standard (0,464), al prezzo di una precision che scende a 0,562; sotto 0,25 il compromesso peggiora rapidamente. Due limiti metodologici vanno dichiarati: la soglia è stata esplorata direttamente sul test set (rigorosamente andrebbe ottimizzata su un validation set separato) e il confronto non è del tutto equo, perché anche agli altri modelli si potrebbe applicare una soglia ottimizzata. L’indicazione generale resta però valida: **in questo problema la calibrazione della soglia incide sui risultati più della scelta dell’algoritmo.**

Tabella 2: Regressione logistica al variare della soglia di decisione (test set). Precision, recall e F1 riferiti alla classe “insolvente”.

Soglia	Accuracy	Precision	Recall	F1
0,50	0,809	0,698	0,240	0,357
0,40	0,812	0,630	0,370	0,466
0,30	0,801	0,562	0,456	0,503
0,25	0,752	0,452	0,560	0,500
0,20	0,610	0,323	0,697	0,442

Numero di alberi della Random Forest. Al variare di `n_estimators` $\in \{10, 50, 100, 200, 500\}$ le metriche si stabilizzano già a partire da 50 alberi (F1 fra 0,459 e 0,467, differenze trascurabili), mentre il tempo di addestramento cresce linearmente, di circa dieci volte fra 50 e 500 alberi. Il parametro non è quindi critico per la qualità delle previsioni: abbiamo adottato 100 alberi come miglior rapporto fra prestazioni e costo computazionale.

Proporzione dello split. Ripetendo l’intera pipeline con split 80/20 anziché 70/30 i risultati non cambiano in modo rilevante (scostamenti entro circa $\pm 0,02$ su tutte le metriche): con 30.000 osservazioni entrambi i training set sono già abbondanti, e ciò che cambia è soprattutto la rumorosità della valutazione sul test set più piccolo. La proporzione dello split, entro valori ragionevoli, non è la leva su cui agire per migliorare i modelli.

5 Discussione

Interpretazione degli errori. In ambito creditizio i falsi negativi (insolventi non individuati, con perdita del credito) sono tipicamente più costosi dei falsi positivi (clienti affidabili segnalati a torto). Con recall fra 0,24 e 0,37 alla soglia standard, tutti i modelli lasciano passare la maggioranza degli insolventi: l’esperimento sulla soglia mostra che già un semplice abbassamento a 0,3 riequilibra sensibilmente il compromesso; in un’applicazione reale la soglia andrebbe scelta in base ai costi effettivi dei due tipi di errore, eventualmente insieme a tecniche per dati sbilanciati (pesi di classe, ricampionamento).

Confronto fra i modelli. La regressione logistica resta preziosa per interpretabilità e costo computazionale minimo, ma il confine lineare non cattura il salto di rischio non lineare legato ai ritardi. Il k -NN non offre interpretabilità e ha predizione lenta (deve calcolare le distanze da tutti i 21.000 esempi di training). La Random Forest è il modello più efficace a soglia standard e la feature importance ne mitiga la minore interpretabilità, pur con un limite noto: la misura tende a sopravvalutare le variabili continue con molti valori distinti.

Limiti dell’analisi. I principali limiti sono tre: (i) il recall modesto sulla classe minoritaria, legato allo sbilanciamento, che abbiamo mitigato esplorando la soglia di decisione ma senza tecniche di ricampionamento, per attenerci agli strumenti del corso; (ii) l’ambiguità dei codici non documentati nelle variabili `PAY_*`, per i quali abbiamo adottato un’interpretazione ragionevole ma non verificabile; (iii) la multicollinearità fra le `BILL_AMT`, che rende inaffidabili i coefficienti individuali di queste variabili nella regressione logistica.

6 Conclusioni

Abbiamo sviluppato un’analisi completa del dataset Credit Card Default: dalla comprensione critica dei dati (sbilanciamento, codici non documentati, ridondanza) al confronto fra tre modelli

di classificazione, fino alla verifica di robustezza dei risultati. Il risultato principale è che il comportamento di pagamento recente — in particolare `PAY_0` — domina la previsione dell'insolvenza, mentre le caratteristiche demografiche sono quasi irrilevanti. A soglia standard la Random Forest è il modello migliore (accuracy 0,813; F1 0,464 sulla classe insolvente), ma l'esperimento sulla soglia mostra che la calibrazione della soglia di decisione incide più della scelta dell'algoritmo: con soglia 0,3 la regressione logistica raggiunge F1 0,503. I risultati sono robusti rispetto alle scelte non critiche (proporzione dello split e numero di alberi): i margini di miglioramento stanno nella gestione dello sbilanciamento. Sviluppi futuri naturali includono pesi di classe o ricampionamento, l'ottimizzazione della soglia su un validation set separato e il feature engineering (ad esempio il rapporto fra importo pagato e fatturato).

Riferimenti bibliografici

- [1] I-Cheng Yeh and Che-hui Lien. The comparisons of data mining techniques for the predictive accuracy of probability of default of credit card clients. *Expert Systems with Applications*, 36(2):2473–2480, 2009.
- [2] Fabian Pedregosa, Gaël Varoquaux, Alexandre Gramfort, Vincent Michel, Bertrand Thirion, Olivier Grisel, Mathieu Blondel, Peter Prettenhofer, Ron Weiss, Vincent Dubourg, Jake Vanderplas, Alexandre Passos, David Cournapeau, Matthieu Brucher, Matthieu Perrot, and Édouard Duchesnay. Scikit-learn: Machine learning in Python. *Journal of Machine Learning Research*, 12:2825–2830, 2011.
- [3] Dheeru Dua and Casey Graff. UCI machine learning repository — default of credit card clients data set. <https://archive.ics.uci.edu/ml/datasets/default+of+credit+card+clients>, 2019.